

# 基于 EEG 的运动想象状态分类

人工智能本硕博 2101 班 梁一凡 U202115210

**摘要** 随着脑机接口 (BCI) 技术的快速发展, 基于脑电图 (EEG) 的运动想象 (MI) 分类已成为 BCI 研究领域的热点之一。本项目旨在探索一种基于迁移学习思想的 EEG 信号处理和分类方法, 以提高 MI 任务的分类准确性和系统性能。首先, 我们对受试者在进行 MI 任务时记录的 EEG 数据进行带通滤波、下采样等预处理。随后, 采用欧式对齐 (Euclidean Alignment) 方法对滤波后的 EEG 信号进行对齐, 以增强信号的空间特征一致性。接下来, 我们求解对齐数据的共空间模式 (Common Spatial Pattern, CSP)。为了训练和评估分类模型, 我们采用了 Braincode 工具箱中的深度学习网络架构 EEG-ITNet 并采用了四折交叉验证方法 (即预留一个受试者的数据作为验证集) 来全面评估模型的性能。实验结果显示, 我们的方法在运动想象二分类任务上取得了平均准确率为 87% 的优异性能。这一结果证明了所提出方法的有效性和深度学习在 BCI 领域的应用潜力。最后, 我们将训练好的模型应用于独立的测试集进行预测, 以验证模型的泛化能力。本研究不仅为基于 EEG 的 MI 分类提供了一种新的视角和方法, 也为 BCI 技术的进一步发展和应用奠定了基础。未来的工作将集中在进一步优化网络结构, 提高模型的实时性和适应性, 以及探索更多的迁移学习和深度学习技术在 BCI 中的应用。

**关键词** 运动想象, 迁移学习, 欧式对齐, 共空间模式, 深度学习

## 1 引言

脑电图 (EEG) 作为一种非侵入性、高时间分辨率的神经电生理技术, 已成为研究大脑活动的重要工具。在运动想象 (Motor Imagery, MI) 分类领域, EEG 的应用经历了从初步探索到深度应用的转变, 与脑-机接口 (BCI) 技术的发展紧密相连。

早期研究主要集中在 20 世纪 70 年代至 90 年代, 学者们开始揭示 EEG 信号与认知过程之间的联系。进入 21 世纪, 随着对 MI 的认知逐渐加深, 研究者们发现, 通过想象特定运动, 可以诱发特定的 EEG 节律变化, 如感觉运动节律 (SMR) 的事件相关去同步化 (ERD) 和事件相关同步化 (ERS) 现象。

随着机器学习算法的引入, 尤其是支持向量机 (SVM) 和随机森林 (RF) 等算法, 为 MI 任务的分类提供了强有力的工具, 使得 EEG 信号的特征提取和模式识别更为精确。

近年来, 深度学习技术的兴起为 EEG 信号处理带来了革命性的变革。深度学习模型, 如卷积神经网络 (CNN) 和循环神经网络 (RNN), 在处理高维 EEG 数据时展现出卓越的能力, 能够自动提取复杂的特征并进行有效的分类。这些模型不仅提高了分类的准确性, 还增强了对噪声的鲁棒性, 为 BCI 系统的实时应用提供了可能。

深度学习在 EEG 信号处理中的应用, 特别是在 MI 分类中, 不仅推动了算法性能的提升, 也为理解大脑在运动想象过程中的复杂动态提供了新的视角。随着算法的不断优化和计算能力的增强, 基于 EEG 的 MI 分类技术在辅助技术、康复训练以及人机交互等领域的应用前景广阔。具体而言, 这一技术有望实现对残疾人士的精准辅助, 通过 BCI 系统提供更为自然和直观的交流与控制方式。在康复训




图 1 运动想象分类任务

练中, MI 分类技术可以帮助患者通过想象运动来促进神经可塑性, 加速恢复过程。此外, 人机交互领域也将受益于这一技术, 通过更深层次的脑机交互实现更高级的交互体验。这些应用不仅将推动神经科学和工程领域的进一步突破, 也将为改善人类生活质量带来实质性的贡献。

## 2 数据采集

采集过程中, 受试者坐在电脑前的椅子上。采集开始时, 电脑屏幕上会出现一个固定的叉, 提示对象准备, 持续 2s; 然后, 一个指向某一个方向的箭头作为视觉提示在屏幕上出现 4s, 在此期间, 受试者根据箭头的方向执行特定的运动想象任务; 然后, 视觉提示从屏幕上消失, 受试者短暂休息 2s。紧接着下一个 trial 开始。

数据来自 7 个健康的受试者, 每一个受试者执行两类运动想象任务: 左手和右手, 脑电信号由一个 59 通道的脑电帽以 1000Hz 的频率记录得到。我们提供了经过预处理后的数据: 下采样到了 100Hz, 带通滤波至 8-30Hz, 划分每一次视觉提示出现后的

0.5 3.5s 之间的 EEG 信号作为一个 trial。每个用户包含 200 个 trial。



图 2 试验数据采集示意图

### 3 迁移学习

EEG 信号很微弱，容易受到身体其它电信号和外界环境干扰，具有很大的个体差异，并且是非平稳的（同一个用户不同时间的 EEG 信号会有差异），所以很难设计一个脑机接口系统，其机器学习模型参数固定且对不同用户、不同脑电帽和不同任务都是最优。通常需要对新用户、新设备和新任务进行校准，但是此校准过程费时费力，对用户不友好，所以缩短或消除此校准过程对于脑机接口系统的推广应用非常重要。

迁移学习是目前脑机接口中减少校准的最重要的方法，其主要思想是通过相似或相关的其它用户、设备或任务的数据来帮助当前用户、设备或任务进行校准。

迁移学习可以用在图 2 流程图的各个部位，并不局限于机器学习部分。比如，可以用迁移学习进行原始脑电数据的对齐，进行信号滤波，进行特征选择等。各个部位的迁移学习可以结合起来达到更好的效果。迁移学习也可以与其它机器学习方法，比如主动学习，相结合来达到更好的效果。在本项目中，我们主要考虑使用欧式对齐（Euclidean Alignment）、共空间模式（Common Spatial Pattern, CSP）和深度神经网络来进行迁移学习。

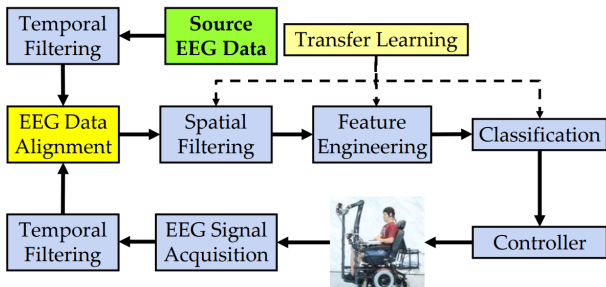


图 3 脑机接口中迁移学习的流程

### 4 欧式对齐

EEG 因其采集方便、安全、时间分辨率高而成为最受欢迎的输入信号。然而，EEG 来自头皮非常

微弱的脑电信号，导致空间分辨率差，信噪比低，因此需要进行数据对齐。欧式对齐是一种适用于同质迁移学习（即特征空间和标签空间相同但边缘概率分布不同）的数据对齐技术。与过去在研究中常用的黎曼对齐相比，欧式对齐有如下优势：

- 直接应用于原始 trail 数据而不是协方差矩阵，处理后可以直接送入分类器中进行训练。
- 它只需要未标记的 EEG trails，而不需要来自新受试者的任何标记信息，因此，它可以用于完全无监督的学习。
- 它的计算速度比黎曼对齐快几倍。




图 4 欧式对齐迁移学习的原理

欧式对齐的基本原理如下：

假设一个受试者进行了  $n$  次 trail，计算其参考矩阵：

$$\bar{R} = \frac{1}{n} \sum_{i=1}^n X_i X_i^T \quad (1)$$

其中  $\bar{R}$  是一个受试者所有协方差矩阵的算数平均值。对其进行对齐：

$$\tilde{X}_i = \bar{R}^{-1/2} X_i. \quad (2)$$

对齐后，所有  $n$  个对齐 trial 的平均协方差矩阵为：

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \tilde{X}_i \tilde{X}_i^T &= \frac{1}{n} \sum_{i=1}^n \bar{R}^{-1/2} X_i X_i^T \bar{R}^{-1/2} \\ &= \bar{R}^{-1/2} \left( \frac{1}{n} \sum_{i=1}^n X_i X_i^T \right) \bar{R}^{-1/2} \\ &= \bar{R}^{-1/2} \bar{R} \bar{R}^{-1/2} = I \end{aligned} \quad (3)$$

经过带通滤波（特别是高通滤波部分）后，各 EEG 通道的均值变为 0，欧式对齐不改变这一点，即欧式对齐后所有受试者的  $X$  均值均为 0（相等）且所有被试者的协方差矩阵均值均为单位矩阵  $I$ （相等），因此不同被试者的协方差矩阵分布更加相似，这在迁移学习中是非常理想的。

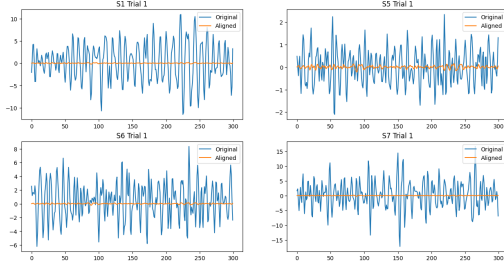


图 5 原始 trail 和欧式对齐 trail 对比

将原始 trail 和欧式对齐的 trial 的结果进行可视化, 可以明显看出经过对齐后的 trial 更一致, 这有利于后续进行迁移学习。




图 6 原始 trail 和欧式对齐 trail t-SNE 可视化对比

## 5 共空间模式

共空间模式 (Common Spatial Pattern, CSP) 是一种对两分类任务下的空域滤波特征提取算法, 能够从多通道的脑机接口数据里面提取出每一类的空间分布成分。共空间模式算法的基本原理是利用矩阵的对角化, 找到一组最优空间滤波器进行投影, 使得两类信号的方差值差异最大化, 从而得到具有较高区分度的特征向量。

以下简要介绍共空间模式的原理:

对于类  $k \in \{-1, 1\}$ , CSP 可以找到一个空间滤波器矩阵  $W_k^* \in \mathbb{R}^{c \times f}$ , 其中  $f$  是空间滤波器的数量 (超参数), 用于最大化这两类的方差之比。(类似于 Fisher 准则)

$$W_k^* = \arg \max_{W \in \mathbb{R}^{c \times f}} \frac{\text{tr}(W^\top \bar{C}_t^k W)}{\text{tr}(W^\top \bar{C}_t^{-k} W)} \quad (4)$$

其中  $\bar{C}_t^k \in \mathbb{R}^{c \times c}$  是  $N_l$  个标签为类  $k$  的 EEG trail 的平均空间协方差矩阵,  $\text{tr}$  是矩阵的迹, 解  $W_k^*$  是  $(\bar{C}_t^{-k})^{-1} \bar{C}_t^k$  的前  $f$  个特征向量的串接。

然后 CSP 串接来自两个类的  $2f$  个空间滤波器

以求得滤波器矩阵  $W^* = \begin{bmatrix} W_{-1}^* & W_1^* \end{bmatrix} \in \mathbb{R}^{c \times 2f}$  并计算空间滤波后的  $\tilde{X}_t^n = W^{*\top} X_t^n \in \mathbb{R}^{2f \times t}$ 。

最后, 滤波后数据的对数方差可以用于提取特征:

$$\mathbf{x}_t^n = \log \left( \frac{\text{diag} \left( \tilde{X}_t^n (\tilde{X}_t^n)^\top \right)}{\text{tr} \left( \tilde{X}_t^n (\tilde{X}_t^n)^\top \right)} \right) \in \mathbb{R}^{1 \times 2f} \quad (5)$$

但是以上原理不够具体, 不适合编程实现。我们继续将原理解析如下:

- 1) **将原始数据按照类别进行分段。**二分类样本数据  $E$  可分类为为第一类样本数据  $E_1$  和第二类样本数据  $E_2$ 。
- 2) **计算分段后的原始数据的协方差矩阵。**协方差矩阵的计算公式为:

$$C_i = \frac{E_i \cdot E_i^\top}{\text{trace}(E_i \cdot E_i^\top)} (i = 1, 2) \quad (6)$$

其中  $\text{trace}(E)$  表示矩阵  $E$  的迹。分别计算分段后原始数据的协方差矩阵,  $C_1$  为第一类样本数据的空间协方差矩阵的期望,  $C_2$  为第二类样本的空间协方差矩阵的期望,  $C_c$  表示两类数据的空间协方差矩阵之和, 则有  $C_c = C_1 + C_2$ 。

- 3) **正交白化变换并对角化。** $C_c$  是正交矩阵, 由奇异值分解得:

$$C_c = U_c \Lambda_c U_c^\top \quad (7)$$

$U_c$  为特征向量矩阵,  $\Lambda_c$  表示特征值的对角阵, 且特征值是降序排列的。

白化转换  $U_c$  得:

$$P = \frac{1}{\sqrt{\Lambda_c}} \cdot U_c^\top \quad (8)$$

将矩阵  $P$  作用于  $C_1$ 、 $C_2$  得:

$$S_1 = P C_1 P^\top, \quad S_2 = P C_2 P^\top \quad (9)$$

$S_1$ 、 $S_2$  具有公共特征向量, 而且存在两个对角矩阵  $\Lambda_1$ 、 $\Lambda_2$  和特征向量矩阵  $B$ , 满足如下条件:

$$S_1 = B \Lambda_1 B^\top \quad (10)$$

$$S_2 = B \Lambda_2 B^\top \quad (11)$$

$$\Lambda_1 + \Lambda_2 = I \quad (12)$$

其中  $I$  为单位阵。由此可以看出  $S_1$  和  $S_2$  的特征值之和等于 1。



- 4) **计算投影矩阵**。对于特征向量矩阵  $Q$ , 当一个类别  $S_1$  有最大的特征值时, 此时另一个类别  $S_2$  有最小的特征值, 因此可以利用矩阵  $Q$  实现两类问题的分类, 得到投影矩阵:

$$W = (Q^T P)^T \quad (13)$$

- 5) **经过投影得到特征矩阵**。将原始脑电数据通过投影矩阵进行投影得到特征矩阵:

$$Z_{M \times N} = W_{M \times M} E_{M \times N} \quad (14)$$

算法生成的 CSP 特征矩阵, 其信息不是等效的。特征信息主要集中在特征矩阵的头部和尾部, 而中间的特征信息不明显可以忽略, 所以选取  $m$  行和后  $m$  行数据作为 CSP 特征提取的特征矩阵。

- 6) **特征归一化**。

$$y_i = \log\left(\frac{\text{var}(Z_i)}{\sum_{n=1}^{2m} \text{var}(Z_n)}\right) \quad (15)$$

其中  $y_i$  为第  $i$  个样本归一化后的特征矩阵。

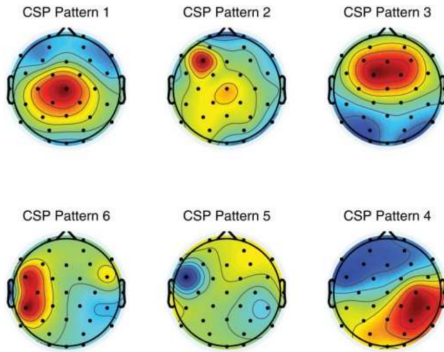


图 7 CSP 模式示意图

在本项目中, 我们直接使用 MNE 库中封装的 CSP 类。CSP 有很多其他的改进, 但是经试验原始版本已经有足够的准确率, 故采用原始版本的 CSP。

## 6 EEG-ITNet

近年来, 深度学习在 BCI 领域的 EEG 分析受到了广泛的关注。在这个正在进行的研究领域, 端到端模型比需要信号变换预分类的传统方法更受青睐。它们可以消除对专家先验信息和手工特征提取的需求。然而, 尽管多种深度学习算法在对运动或心理任务进行分类时达到了很高的准确性, 但它们往往面临缺乏可解释性的问题, 因此不太受神经科学界的青睐。这个问题背后的原因可能是大量的参数和深度神经网络捕捉微小但不相关的判别特征的

敏感性。本项目使用一种端到端深度学习架构, 称为 EEG-ITNet, 使用初始模块和扩展的因果卷积, 可以从多通道 EEG 信号中提取丰富的频谱、空间和时间信息, 并且比其他现有的端到端架构具有更低的复杂性。

EEG-ITNet 的总体架构如图所示, 由 4 个主要块组成: Inception block、Temporal convolution (TC) block、Dimension reduction (DR) block、Classification block。




图 8 EEG-ITNet 总体架构

- 1) **Inception block**. 学习过程始于三组平行的层, 每组都包含一个沿时间轴的二维卷积层, 其起到频率滤波的作用, 随后是一个起到空间滤波作用的二维深度卷积层。添加具有不同卷积核大小的初始模块消除了对固定长度核的需求, 并使网络能够学习代表各种频率子带的滤波器。我们稍后将展示, 核的长度越长, 就越有可能学习低频分量中的特征。深度卷积的核大小等于数据集中电极的数量, 以设计一个能将所有电极组合起来以找到大脑活动源的空间滤波器。因此, 在 Inception block 之后获得的张量代表了不同频率子带中信号源的信号。此块以非线性激活函数和 dropout 结束, 分别用于让网络学习更复杂的非线性空间信息以及避免过拟合。




图 9 Inception block 示意图

- 2) **TC block**. 在提取不同信息频率子带的源后, 利用 TCN 架构提取时间序列的判别性时间特征, 同时考虑时间序列的历史特征。TC 块由多个残差块组成, 每个残差块由深度因果卷积层组成,

前导为零填充, 然后是激活函数和 dropout。使用深度因果卷积, 然后进行批归一化, 而不是权重归一化。由于 Inception block 的输出表示源域中的信号, 因此使用深度因果卷积来确保分别提取每个源的时间信息。在此块之前还有一个平均池化层, 以减少数据维度并避免过拟合。




图 10 TC block 示意图

3) **DR block.** TC 块的输出基本上包含从各种频谱源提取的时序信息。因此, 我们使用  $1 \times 1$  卷积层来组合这些时间特征, 并控制用于执行分类任务的最终特征的数量。除了激活函数和 dropout 层之外, 该块还以平均池化层结束, 以进一步降低张量维度。

4) **Classification block.** 该块是 EEG-ITNet 的最后一块, 包含一个紧跟在展平层之后的全连接层, 该层具有 softmax 激活函数。




图 11 DR block 和 Classification block 示意图

虽然这个网络宣称可以实现端到端的高准确率分类, 但在实际操作中, 其对没有进行欧式对齐的原始 EEG 信号分类的准确率让人并不满意, 因此输入的数据是经过带通滤波、欧式对齐并提取共空间模式后的特征。

## 7 训练设置及结果

在实验中, 我们将求解的共空间模式数设置为 5, 采用四折交叉验证, 学习率设置为 0.01, 权重衰减设置为 0.2, 批大小设置为 10, 训练轮次设置为 200, dropout 概率设置为 0.4。改变超参数的设置可能会提高模型性能, 但囿于时间有限没有充分实验。

为了验证欧式对齐和共空间模式的作用, 进行了消融实验, 结果如下表。可以看出, 欧式对齐和共空间模式对于迁移学习的准确率有显著提高, 而

表 1 分类准确率

	Net	Net+CSP	Net+EA	Net+EA+CSP
Subject 1	56.5%	70%	82%	87.5%
Subject 2	55.5%	73.5%	84%	87.5%
Subject 3	56%	71%	80.5%	87%
Subject 4	56.5%	71%	82%	87%
Average	56.125%	71.375%	82.12%	87.25%

且二者结合可以进一步提高分类的准确率和泛化性能。这充分展示了这两种技术在迁移学习任务中的有效性。

取每一折上准确率最高的模型在测试集上进行预测, 并采用投票法决定最终的预测结果。

## 8 结论

本文验证了基于欧式对齐和共空间模式的深度学习在运动想象任务上进行迁移学习的可行性, 结果表明我们的方法具有良好的准确率和泛化性。值得注意的是, 虽然很多深度学习算法宣称拥有端到端学习的能力, 但在实践中往往表现不佳。未来可能改进的方向有使用更好的数据对齐方式, 使用更好的滤波算法和使用更好的分类算法。

## References

- 1 A. Salami, J. Andreu-Perez and H. Gillmeister, "EEG-ITNet: An Explainable Inception Temporal Convolutional Network for motor imagery classification," in IEEE Access, doi: 10.1109/ACCESS.2022.3161489.
- 2 H. He and D. Wu, "Transfer learning for brain-computer interfaces: A Euclidean space data alignment approach," IEEE Trans. on Biomedical Engineering, vol. 67, no. 2, pp. 399 – 410, 2020.
- 3 D. Wu\*, X. Jiang and R. Peng, "Transfer Learning for Motor Imagery Based Brain-Computer Interfaces: A Tutorial," Neural Networks, 153:235-253, 2022.
- 4 Lemm S, Blankertz B, Curio G, Muller K. Spatio-spectral filters for improving the classification of single trial EEG. IEEE Trans Biomed Eng. 2005;52(9):1541 – 8.
- 5 共空间模式 Common Spatial Pattern(CSP) 原理和实战 <https://blog.csdn.net/zyb228/article/details/101163540>
- 6 Robin Tibor Schirrmeister, Jost Tobias Springenberg, Lukas Dominique Josef Fiederer, Martin Glasstetter, Katharina Eggensperger, Michael Tangermann, Frank Hutter, Wolfram Burgard, and Tonio Ball. Deep learning with convolutional neural networks for EEG decoding and visualization. Human Brain Mapping, 38(8):3954 – 3969, 2017. doi:10.1002/hbm.23730.
- 7 Alexandre Gramfort, Martin Luessi, Eric Larson, Denis A. Engemann, Daniel Strohmeier, Christian Brodbeck, Roman Goj, Mainak Jas, Teon Brooks, Lauri Parkkonen, and Matti S. Hämäläinen. MEG and EEG data analysis with MNE-Python. Frontiers in Neuroscience, 7(267):1 – 13, 2013. doi:10.3389/fnins.2013.00267.